

DAILY RESEARCH BRIEF

每日 MIR 論文精選

今天先看最可能推動 MeanAudio 的論文，再補一篇對 karaoke-jp 或 MIR 觀點有啟發的工作。重點是能不能轉成下一個可驗證的小實驗。

閱讀順序

- 01 MeanAudio 優先。** 生成、flow、caption、codec、評估與 reward alignment。
- 02 karaoke-jp 第二。** 分離、pitch、lyrics alignment、score/MIDI 與 rendering。
- 03 只收高品質。** 新穎度、重要性、baseline、資料與可落地性一起看。

01

MeanAudio

新

更新 2026-05-26 · 1 天內

Adversarial Dual On-Policy Distillation from Expressive Flow-based Teacher

Learning from demonstrations in embodied control is often cast as behavioral cloning, and recent diffusion or flow-matching policie...

貼近主線

text-to-audio/music

flow/diffusion

為什麼看

先看它是否能改善 text-to-audio / text-to-music 的資料、caption、latent flow、codec、評估或 reward alignment。

可行性

高：如果方法牽涉資料、caption、evaluation 或 sampling，可以拆成一個單變因 ablation，先用少量音訊檢查方向。

Problem / 問題

Learning from demonstrations in embodied control is often cast as behavioral cloning, and recent diffusion or flow-matching policies improve this paradigm by modeling multi-modal expert actions.

Method / 方法

Yet these methods remain offline supervised learners: the policy is trained only on expert states and receives no corrective signal on the states it actually visits.

Data / 資料

優先檢查使用的資料集、benchmark、音訊樣本、程式碼與 baseline；若論文沒有清楚交代，先把它列為待驗證。

Findings / 結果

On-policy distillation (OPD) offers a natural remedy, but standard OPD assumes a strong fixed teacher, which is unavailable in demonstration-only control.

Limitations / 限制

注意是否只靠單一自動化指標、缺少音訊樣本、baseline 偏弱，或把 speech/TTS 成果過度推到 music/audio generation。

Editor note / 編者註

先看它是否能改善 text-to-audio / text-to-music 的資料、caption、latent flow、codec、評估或 reward alignment。下一步：把最有關的 trick 寫成一個小實驗：固定模型與資料，只替換一個策略，量化 CLAP 類指標後補主觀聆聽。

Metadata / 索引資訊

作者 Zhenglin Wan, Jingxuan Wu,
Xingrui Yu, Chubin Zhang,
Mingcong Lei 等 8 位

來源 <https://arxiv.org/abs/2605.27095v1>

關聯分數 MeanAudio 3 / karaoke 0 · max 3

02

MeanAudio

新

更新 2026-05-26 · 1 天內

JLT: Clean-Latent Prediction in Latent Diffusion Transformers

Flow matching with clean-data prediction has shown that regressing the clean point can exploit low-dimensional structure more effec...

貼近主線

text-to-audio/music

flow/diffusion

為什麼看

先看它是否能改善 text-to-audio / text-to-music 的資料、caption、latent flow、codec、評估或 reward alignment。

可行性

高：如果方法牽涉資料、caption、evaluation 或 sampling，可以拆成一個單變因 ablation，先用少量音訊檢查方向。

Problem / 問題

Flow matching with clean-data prediction has shown that regressing the clean point can exploit low-dimensional structure more effectively than predicting an ambient noised quantity.

Method / 方法

We ask whether this principle remains useful after images are mapped into a learned latent space, where compression has already removed much of the raw pixel variability.

Data / 資料

優先檢查使用的資料集、benchmark、音訊樣本、程式碼與 baseline；若論文沒有清楚交代，先把它列為待驗證。

Findings / 結果

We introduce JLT, a 130M latent diffusion Transformer over frozen FLUX.2 VAE codes, and compare clean-latent prediction with a matched velocity-prediction DiT under the same representation, backbone, and training settings.

Limitations / 限制

注意是否只靠單一自動化指標、缺少音訊樣本、baseline 偏弱，或把 speech/TTS 成果過度推到 music/audio generation。

Editor note / 編者註

先看它是否能改善 text-to-audio / text-to-music 的資料、caption、latent flow、codec、評估或 reward alignment。下一步：把最有關的 trick 寫成一個小實驗：固定模型與資料，只

替換一個策略，量化 CLAP 類指標後補主觀聆聽。

Metadata / 索引資訊

作者 Funing Fu, Tenghui Wang,
 Junyong Cen, Qichao Zhu, Guanyu
 Zhou

來源 <https://arxiv.org/abs/2605.27102v1>

關聯分數 MeanAudio 3 / karaoke 0 · max 3

今天的取捨

不要把新論文等同於好論文。今天的排序會先照你的研究主線，再看新穎度與可落地性。

2

papers

09:00

Taipei

深讀前先問：它能否改善資料、caption、評估、速度、可控性或 alignment？不能的話，只留下概念。

Generated at 2026-05-27 16:22:43 Asia/Taipei.

Generated by the local MIR paper automation. Product standard 2026-05-26 · 1d5f843f0d.